

# Predição de Alfabetização Infantil & Análise de Risco Educacional

## O Desafio da Gestão Pública

O **Compromisso Nacional Criança Alfabetizada** estabelece que 100% dos alunos do 2º ano atinjam proficiência (743 pontos SAEB) até **2030**.

Acompanhar apenas relatórios históricos consolidados impede ações corretivas ágeis, pois quando o resultado é publicado o ciclo letivo já terminou.

## Solução de Inteligência Analítica

Construção de um **Sistema Preditivo de Alerta Precoce** para identificar redes municipais em situação de vulnerabilidade.

- Antecipação de riscos para o Ministério da Educação (MEC).
- Direcionamento de recursos e apoio técnico prioritário (FUNDEB).
- Tomada de decisão orientada por dados de 5.570 municípios.

# Partição Temporal & Blindagem Total contra Data Leakage

## 📁 Base de Dados Gold (16.710 Registros)

- **Histórico Escolar:** Indicadores de 1 e 2 anos anteriores (Lag 1 e Lag 2).
- **Dinâmica Temporal:** Tendência histórica ( $\Delta = \text{Lag}_1 - \text{Lag}_2$ ) e gaps prévios vs metas.
- **Socioeconomia:** IDHM, PIB per capita e Volume de Matrículas.
- **Territorial:** 27 UFs e 5 Grandes Regiões do Brasil.

## 🛡️ Pipeline Scikit-Learn & Divisão Temporal

Garantia de **Zero Data Leakage** (direto, temporal e de grupo):


- ColumnTransformer integrado (Imputação, Scaler e Encoder).
- **Partição Temporal Estrita:** Treino em 2022-2023 (11.140 amostras) e Teste Holdout em 2024 (5.570 amostras).
- StratifiedGroupKFold agrupado por município na validação cruzada.
- Exclusão total de variáveis do ano corrente ( $t$ ) do vetor  $X$ .

# Comparação de Modelos com Otimização (GridSearchCV)

| Modelo                         | CV Bal Acc | ROC-AUC Teste | Recall Risco (0) | Bal Acc Teste |
|--------------------------------|------------|---------------|------------------|---------------|
| HistGradientBoosting 🏆         | 0.7883     | 0.9271        | 85.12%           | 83.97%        |
| Regressão Logística (Baseline) | 0.7879     | 0.9287        | 84.62%           | 83.77%        |
| Random Forest (Otimizado)      | 0.7866     | 0.9163        | 86.67%           | 83.65%        |

92.7%  
ROC-AUC HOLDOUT 2024


85.1%  
RECALL DE MUNICÍPIOS EM RISCO




# Interpretabilidade com SHAP Values (TreeExplainer)

## Fatores Determinantes na Alfabetização

- 1º Gap vs Meta Municipal: Maior peso absoluto ( $\text{SHAP} = 0.180$ ). Distância prévia em relação à meta pactuada.
- 2º Tendência Histórica ( $\Delta$ ): ( $\text{SHAP} = 0.052$ ). Velocidade de aceleração do aprendizado em ciclos anteriores.
- 3º Inércia Histórica ( $\text{Lag}_{-1}$ ): ( $\text{SHAP} = 0.026$ ). Desempenho escolar prévio consolidado.
- 4º Gap vs Meta Nacional & IDHM: Proximidade da meta federal e blindagem estrutural socioeconômica.



# Quadrante de Risco, Clusters e Ações Governamentais



## 🚨 Diagnóstico de Vulnerabilidade (2.964 Municípios em Risco)

Identificação de redes municipais com histórico  $< 50\%$  e tendência de queda. Detecção de 4 perfis socioeconômicos via clustering K-Means.

## 🏛️ Recomendações para MEC / FUNDEB

- **Repasse** Priorização financeira para o cluster de vulnerabilidade severa.
- **Discrecionários:**
- **Mentoria Pedagógica:** Envio de equipes técnicas antes do ciclo do SAEB.
- **Calibragem de Metas:** Ajuste realista dos planos municipais.
- **Equidade Territorial (Fairness):** Auditoria comprovando alta sensibilidade (82% a 88%) em todas as 5 regiões.

# Conclusão & Impacto Educacional

 **Excelência Metodológica**

Partição Temporal (2022-2023 treino, 2024 teste),  
StratifiedGroupKFold e 85.12% de Recall na detecção de  
risco.

 **Transparência Total (XAI & Fairness)**

Explicabilidade SHAP (Beeswarm, Bar, Waterfall) e  
Auditoria de Equidade Regional e IDHM.

 **Impacto Social Real**

Transformação de dados brutos da Camada Gold em  
inteligência preventiva para o futuro da educação básica.

Repositório Oficial: [github.com/gustavoschutt/Tech-Challenge-Fase-3](https://github.com/gustavoschutt/Tech-Challenge-Fase-3)